文梓锋 ZIFENG WEN

哈尔滨工业大学（深圳）| 伦敦帝国理工学院
邮箱: vincent20031014@foxmail.com | 手机: +86 136-6263-4296

教育背景

伦敦帝国理工学院（Imperial College London） *2026.09-2027.09*

- **MSc Advanced Computing (1YFT) —— 已获得 Offer**

哈尔滨工业大学（深圳） 985 *2022.08-2026.07*

学院：信息学部计算机科学与技术学院 专业：计算机科学与技术 本科 *中国深圳*

- **GPA:** 94.21 / 100 (3.93 / 4.00) **RANK:** 2 / 317 **(Top 1%)**
- **核心课程:** 大语言模型：基础、实践与挑战(100), 数理逻辑 (100), ACM 程序设计 (100), 计算机设计与实践 (99), 面向对象的软件构造导论 (98), 人工智能(98), 面向领域的计算机系统设计与开发实践(97), 高级语言程序设计 (96), 智能证券投资-量化(96)
- 计算机科学与技术学院 2026 届**本科生优秀毕业论文 (全院仅 16 人获奖)**

伦敦帝国理工学院（Imperial College London） *2024.01-2024.02*

2024 年伦敦帝国理工学院-**Data Science** 寒假交流交换项目 *英国伦敦*

- 学习 PyTorch 深度学习框架，拥有完整的模型微调实战经验，能够通过数据增强策略和数据加载器优化，有效提升训练效率和模型性能。
- 基于多模态 MRI（T1/T1c/T2/FLAIR）构建脑肿瘤 3D 分割系统，以 **U-Net** 作为核心分割网络生成肿瘤区域掩膜，实现肿瘤区域精确分割与可视化分析。
- **获评总体成绩 A 级（Distinction）**，并荣获**最佳展示奖和二等奖学金。**

论文发表

Yiqing Huang, **Zifeng Wen**, Yixuan Kong, Jiaole Wang, Shuang Song*, *"Design of a Miniaturized Wire-Driven Continuum Surgical Robot for Remote Operation in Minimally Invasive Surgery"*, presented at the 2025 IEEE International Conference on Real-time Computing and Robotics (IEEE **RCAR** 2025).

实习经历

小红书-业务技术部-社区工程部-互动 PE 组 *2026.03-2026.06*

产品工程师（AI-评论社区） *中国上海*

- 面向评论社区场景负责 AI 产品工程化落地，完成从需求洞察、策略设计、模型方案选型到工程部署的全链路闭环，推动 AI 能力与社区业务深度结合，优化用户互动体验。
- **评论意图建模与端侧推理：**基于用户行为、会话上下文、帖子语义及评论关注度等多模态信号，设计评论意图预测系统；训练 XGBoost 与 LinearSVC 模型，并部署至 iOS Core ML，实现低延迟端侧实时推理。
- **@点点 Follow-up Agent：**构建基于大语言模型的用户“蹲后续”意图识别 Agent，覆盖作者更新、活动进展及产品发布等场景；设计订阅目标抽取、内容检索与更新检测链路，实现自动订阅与个性化通知。
- **AI 收藏管理 Agent：**基于 Embedding 语义表示与聚类算法，构建用户收藏内容智能整理系统；设计 Human-in-the-Loop Agent 工作流，实现主题专辑的自动生成、持续优化与动态维护，支持长期知识管理与内容沉淀。

影石-技术中心-应用软件部-软件开发部-主框架组-素材管理组 *2025.11-2026.03*

Android 开发工程师（负责相册、下载、导出和缩略图等模块） *中国深圳*

- **缩略图模块与算法能力工程化落地：**负责缩略图模块的架构与性能优化，对接研究院算法组完成模型能力在客户端侧的工程化接入，参与模型推理接口设计与结果消费流程，支持算法结果在相册与素材管理场景中的稳定展示与业务集成。
- **Live Photo SDK 接入与工程化落地：**多厂商 Live Photo SDK 集成，并支持 Live Photo 在 App 内的相册浏览、下载与导出。
- **完成 25 项高优需求**，包含 16 项业务需求与 9 项缺陷修复，相关成果已在 ***Insta360 APP*** 主线版本稳定运行。

美团-核心本地商业-视频技术部-直播营销组 *2025.04-2025.08*

JAVA 软件开发工程师 *中国北京*

- **主播权限治理：**重构主播抽奖权限配置逻辑，引入缓存 + API 双层校验，实现权限实时判定与自动化控制。
- **营销变更溯源：**基于 AOP 实现红包雨、分享裂变等核心流程的全链路变更追踪，实现无侵入监控与高效异常溯源。
- **SQL 架构优化：**将 Java 内嵌 SQL 重构为 XML 配置，通过一致性校验与字段级监控提升可维护性与定位效率。
- **完成 14 项高优需求**，包含 10 项业务需求与 4 项技术需求，相关成果已在核心直播场景稳定运行。

深圳市维海德技术股份有限公司-视频研究院-AI 科 *2024.12-2025.02*

计算机视觉算法工程师 *中国深圳*

- **3D 人体重建与可驱动建模：**构建基于 **NeRF** 与 **3D Gaussian Splatting（3DGS）**的高精度 3D 人体重建流程，支持姿态变化下的稳定重建与可驱动虚拟数字人建模。
- **统一评测与性能分析：**搭建 NeRF/3DGS 统一评测框架，结合 PSNR、SSIM、LPIPS 等指标及几何一致性分析，系统评估

重建质量、显存占用与交互帧率，为算法选型与参数设计提供依据。

- **人-场景交互生成建模：**复现扩散式自回归人-场景交互模型（*Scaling Up Dynamic Human-Scene Interaction Modeling*），基于 **TRUMANS** 数据集实现时序条件建模，并与 **NeRF/3DGS** 渲染模块耦合，实现连续动作预测与自适应场景响应。

项目经历

Learn-Claude-Code：Agent Harness 核心机制复现与工程实现 *2026.05-2026.07*

项目描述：以 Claude Code 为参考对象，系统分析并复现 Agent Harness 的核心架构设计，探索智能体在上下文管理、工具调用、任务调度与能力治理方面的工程实现。

- Agent 执行框架：复现 Agent Loop, Tool Use, Skill Loading 等核心机制，构建统一执行循环与能力调度框架。
- 上下文与记忆管理：实现 Context Compaction, Memory Management 与长上下文检索能力，支持多轮任务执行过程中的上下文压缩与状态保持。
- 任务编排与能力扩展：实现 Task Scheduling、Subagent 协作与 MCP 能力路由机制，支持复杂任务拆解、工具编排与多能力协同执行。

HelloAgents：多智能体框架与旅行规划系统 *2026.02-2026.03*

项目描述：构建支持多智能体协作、记忆管理、工具调用与 RAG 检索的 Agent 框架，集成经典智能体推理范式与长期记忆机制；基于高德地图 MCP 开发智能旅行规划系统，实现从需求理解、任务拆解到工具调用与结果生成的端到端智能决策流程。

- **智能体推理框架：**实现 ReAct、Plan-and-Solve、Reflection 等经典 Agent 推理范式，封装统一 LLM 接口与 ToolExecutor，实现 Thought→Action→Observation 推理链及工具调度机制。
- **记忆与检索系统：**设计 Working、Episodic、Semantic、Perceptual 四层记忆体系与 MemoryManager，集成 Qdrant 向量检索与 RAG 增强能力。
- **多智能体应用落地：**基于 FastAPI、Vue3 与高德地图 MCP 构建旅行规划系统，实现景点推荐、路线规划、地图绘制、行程编辑及结构化输出生成。

MiniMind：轻量级大语言模型训练与推理框架 *2026.01-2026.02*

项目描述：基于 PyTorch 原生手写实现 Decoder-only LLM（26M~145M 量级），构建覆盖预训练、监督微调（SFT）、偏好优化、知识蒸馏及推理部署的完整训练体系；模型侧支持 Pre-LN 架构、RMSNorm、SwiGLU、RoPE（含 YaRN 长上下文扩展）、GQA 与高效 KV Cache；训练框架支持 DDP 分布式并行、AMP 混合精度训练、断点续训与实验可视化管理。

- **模型架构实现：**实现 Pre-LN（Norm→Compute→Residual）+ RMSNorm 稳定深层训练；Attention 侧对 Q/K 应用 RoPE，并支持 YaRN rope scaling 长上下文外推；FFN 采用 SwiGLU；使用 GQA 减少 KV Cache 开销。
- **推理性能优化：**基于 PyTorch 2 的 scaled_dot_product_attention (采用“分块+ 融合计算”的注意力内核)；并保留标准 QK^T + mask + softmax 的参考实现用于兼容与对齐验证，两种实现均严格遵循因果 Mask，保证自回归场景下的数值一致性。

科研经历

基于 Agent Memory 的智能体推理增强研究 *2026.03-2026.07*

算法研究助理（导师: 刘学博教授，哈尔滨工业大学（深圳））

项目描述：针对 LLM Agent 在长时程软件工程任务中存在历史经验利用不足、上下文窗口受限等问题，调研并分析 Agent Memory 领域前沿工作，探索长期记忆机制在 Software Engineering Agent 中的应用，并基于 SWE-bench 开展实验研究。

- 系统调研 AgeMem、G-Memory、MemGas、BMAM 等代表性工作，归纳长期记忆、共享记忆及层次化记忆机制设计范式。
- 基于记忆检索与经验复用思想，设计 Agent Memory 实验框架，实现历史轨迹存储、语义检索与动态更新机制，并构建支持 LLM、Memory 与 Multi-Agent 协作的统一实验平台，用于研究不同记忆策略对 Agent 推理能力的影响。
- 基于 SWE-bench 搭建自动化评测流程，从问题解决率、推理成本及上下文利用效率等维度开展实验分析。

折叠视界：沉浸式 VR 平台下的蛋白质结构动态可视化与 AI 辅助设计 *2025.03-2025.07*

算法研究助理（导师: 陈俊杰教授，哈尔滨工业大学（深圳））

项目描述：构建沉浸式蛋白质结构设计与验证平台，将扩散生成模型与结构–功能评估体系集成至 VR 交互环境，实现从蛋白骨架生成、序列设计到结构与界面验证的实时可视化闭环。

- 搭建 Python 后端服务，解析 VR 端（C#）控制参数与 PDB 结构，封装 RFdiffusion 接口实现结构约束下的骨架生成。
- 集成 ProteinMPNN 进行结构条件序列设计，并调用 RF3 进行回折叠预测，在线计算 RMSD、pTM 等结构一致性指标。
- 项目成果已转化为 **2 项国家发明专利**和 **1 项软件著作权**。

奖学金及竞赛奖项

- **计算机学院本科生学业奖学金：**2024–2025 二等奖学金；2023–2024 三等奖学金；2022–2023 二等奖学金
- 2023 年“高教杯”全国大学生数据建模竞赛**省级一等奖（担任队长）** *2024.01*
- 蓝桥杯全国软件和信息技术专业人才大赛广东赛区 C\C++程序设计大学 A 组**省级一等奖** *2023.04*

语言

- **英语水平:** IELTS Overall 8.0 (L7.5, R8.5, W8.5, S6.5)